Universidade Federal do Rio de Janeiro

Escola Politécnica

Tuma: MB3B-4
MBA em Big Data, Business Intelligence e Business Analytics
Disciplina:Data Mining

Solução em Data Mining

Definições de Negócio, Técnicas de Desenvolvimento e Tratamento de Dados

Empresa: Moda Fitness BR
Segmento: Indústria e Varejo Têxtil

Grupo III:

Carlos Henrique Ramalho P Linhares
Eralda Ferreira da Silva
Felipe Nascimento da Cruz
Flavia Lucena de Araújo
Rafael Castilho Freire

1. Resumo Executivo

Este relatório apresenta o processo completo de mineração de dados aplicado à empresa Moda Fitness BR, cobrindo desde a ingestão e limpeza dos dados brutos até a geração de previsões de faturamento para o ano de 2026. O trabalho segue as etapas do processo KDD (Knowledge Discovery in Databases): seleção, pré-processamento, transformação, mineração e interpretação dos resultados, alinhadas com a metodologia CRISP-DM apresentada na disciplina Data Mining.

A base analisada contém 251.000 transações de venda realizadas entre abril de 2021 e março de 2026. Três algoritmos de aprendizado de máquina e estatística foram treinados e combinados em um modelo ensemble, alcançando erro médio (MAPE) de 4,9% na predição do período de teste. A projeção de faturamento total para 2026 é de R$ 9.947.533,63, representando variação de -0,03% em relação ao faturamento de 2025 (R$ 9.950.453,60).

Indicador	Valor
Total de transações analisadas	251.000
Período histórico	Abr/2021 – Mar/2026
Número de produtos	30
Número de categorias	6
Janela de treino	Abr/2022 – Dez/2024
Janela de validação	Jan/2025 – Dez/2025
Janela de teste	Jan/2026 – Mar/2026
MAPE do modelo final (Ensemble)	4,9%
Faturamento Real 2025	R$ 9.950.453,60
Faturamento Projetado 2026	R$ 9.947.533,63
Crescimento anual projetado	-0,03%

2. Fundamentação Teórica: Data Mining

2.1 Conceito e Contexto

Data Mining é o processo de descoberta automática ou semiautomática de padrões significativos, correlações, anomalias e tendências em grandes conjuntos de dados. Trata-se de uma disciplina interdisciplinar que reúne técnicas de estatística, aprendizado de máquina, reconhecimento de padrões e banco de dados. Segundo Fayyad, Piatetsky-Shapiro e Smyth (1996), Data Mining é uma etapa do processo mais amplo denominado KDD (Knowledge Discovery in Databases), sendo responsável pela aplicação de algoritmos que produzem modelos capazes de generalizar conhecimento a partir dos dados observados.

No material de aula da disciplina, Data Mining é definido como o processo de explorar grandes volumes de dados para identificar padrões, tendências e informações úteis, com o objetivo de apoiar a tomada de decisões e descobrir insights que não seriam facilmente visíveis por métodos tradicionais. O professor enfatiza ainda que a disciplina combina técnicas analíticas, estatísticas e de aprendizado de máquina (Machine Learning) em grandes conjuntos de dados, posicionando-a como distinta do Business Intelligence (BI): enquanto o BI transforma dados operacionais em informações táticas, o Data Mining gera novo conhecimento ao revelar padrões e relações ocultas que contribuem para o planejamento estratégico.

Hand, Mannila e Smyth (2001) sintetizam o objetivo central da disciplina como a descoberta de estruturas interessantes, inesperadas ou valiosas em grandes conjuntos de dados — definição que fundamenta a abordagem adotada neste projeto, cujo foco é revelar padrões de sazonalidade e tendência no faturamento do varejo fitness.

No contexto do varejo, a mineração de dados é aplicada para compreender o comportamento do consumidor, otimizar estoques, segmentar clientes e realizar previsões de demanda (HAN; KAMBER; PEI, 2011). O próprio material da disciplina destaca aplicações diretas no varejo, como previsão de demanda por SKU, gestão de estoques, churn e fidelização (LATTA, 2026) — todas dimensões relevantes para a Moda Fitness BR. A previsão de séries temporais de faturamento, foco deste projeto, permite que gestores tomem decisões antecipadas sobre compras, campanhas promocionais e dimensionamento de equipes.

2.2 O Processo KDD

O processo KDD estrutura-se em cinco fases sequenciais, conforme descrito por Fayyad, Piatetsky-Shapiro e Smyth (1996) e reafirmado no material de aula (LATTA, 2026). Todas as fases foram executadas neste projeto:

Fase KDD	Descrição / Ação no Projeto
1. Seleção	Identificação e extração dos dados relevantes das fontes brutas (fVendas, dClientes, dProdutos, fEstoque).
2. Pré-processamento	Tratamento de valores ausentes, remoção de duplicatas, validação de integridade referencial e regras de negócio.
3. Transformação	Feature engineering: criação de variáveis derivadas, agregações temporais, variáveis de sazonalidade e lags.
4. Mineração	Aplicação de algoritmos preditivos (SARIMA, Ridge Regression, LightGBM) e combinação via ensemble.
5. Interpretação	Avaliação dos erros (MAPE), extração de pesos ótimos, geração da previsão financeira 2026 e documentação.

Conforme destacado pelo Prof. Latta (2026), as etapas da mineração de dados associadas ao KDD incluem a coleta (Data Selection), a preparação (Data Preprocessing), a aplicação de algoritmos, e a análise e interpretação dos resultados (Evaluation & Interpretation), sendo que o conhecimento gerado é o produto final do processo — e não os algoritmos em si.

2.3 A Metodologia CRISP-DM

O CRISP-DM (Cross-Industry Standard Process for Data Mining) é o modelo de processo mais amplamente utilizado em projetos de mineração de dados na indústria. Originalmente publicado em 2000 e posteriormente adaptado pela IBM em 2011, o guia descreve o ciclo de vida da mineração de dados em seis fases iterativas (IBM, 2011).

Segundo o material da disciplina, o CRISP-DM é um modelo de processo que fornece

uma visão geral do ciclo de vida da mineração de dados e, como metodologia, inclui descrições das fases típicas de um projeto, as tarefas envolvidas em cada fase e uma explicação dos relacionamentos entre essas tarefas em um ciclo iterativo (LATTA, 2026). O professor ressalta que o CRISP-DM tornou-se o modelo mais utilizado em Data Mining devido à sua estrutura flexível e iterativa, alinhada aos objetivos de negócios, e sua aplicabilidade ampla em diferentes setores, com ênfase na compreensão do problema, qualidade dos dados, validação contínua e implementação prática.

Uma característica fundamental do CRISP-DM — e que o diferencia de abordagens lineares — é que o entendimento do negócio permeia todo o ciclo: a todo momento o valor da entrega é avaliado pelo entendimento do negócio, verificando se o que está sendo construído agrega valor à empresa e está de acordo com seus objetivos estratégicos (LATTA, 2026). As seis fases do modelo e sua aplicação direta neste projeto são descritas a seguir:

Fase CRISP-DM	Aplicação neste Projeto
1. Entendimento do Negócio	Compreensão dos objetivos do projeto a partir da perspectiva de negócio. Neste projeto: prever o faturamento mensal para 2026 com erro inferior a 10%, apoiando o planejamento comercial da Moda Fitness BR.
2. Entendimento dos Dados	Recolhimento e familiarização com as quatro tabelas brutas (fVendas, dClientes, dProdutos, fEstoque), identificando problemas de qualidade, volumes e estrutura (251.000 registros, período abr/2021–mar/2026).
3. Preparação dos Dados	Construção do conjunto de dados analítico final: imputação de nulos, remoção de duplicatas, feature engineering de clientes e vendas, agregação diária/mensal e criação de lags, médias móveis e transformadas de Fourier. Fase executada nos Scripts 01 a 09.
4. Modelagem	Aplicação e calibração de três modelos complementares: SARIMA (estatístico), Ridge Regression com Fourier (prophet-style) e LightGBM (gradient boosting).

Fase CRISP-DM	Aplicação neste Projeto
	Parâmetros otimizados por grid search sobre o conjunto de validação. Scripts 11 a 15.
5. Avaliação	Verificação do desempenho dos modelos frente ao objetivo de negócio. O ensemble final atingiu MAPE de 4,9% no conjunto de teste (jan–mar/2026), abaixo do limiar de 10% estabelecido como critério de aceitação.
6. Implantação	Apresentação do conhecimento gerado sob forma de relatório executivo, projeção financeira mensal para abr–dez/2026 e pipeline reprodutível (17 scripts numerados), disponibilizado publicamente em repositório GitHub para rastreabilidade e auditoria.

A natureza iterativa do CRISP-DM foi evidente neste projeto: a fase de Preparação dos Dados (Scripts 01 a 09) foi revisitada durante a Modelagem ao perceber-se que certas features de sazonalidade precisavam de ajuste fino para reduzir o MAPE do LightGBM. Essa retroalimentação é prevista pelo modelo e contribuiu para o resultado final de 4,9% de erro.

2.4 Séries Temporais e Previsão de Demanda

Uma série temporal é uma sequência de observações coletadas em instantes de tempo sucessivos e igualmente espaçados. No varejo, o faturamento diário constitui uma série temporal sujeita a tendência (crescimento ou declínio de longo prazo), sazonalidade (padrões cíclicos como alta de vendas no fim do ano) e ruído estocástico. A literatura classifica os métodos de previsão em três grandes famílias:

Família	Exemplos	Características
Estatísticos	ARIMA, SARIMA, Holt-Winters	Capturam autocorrelação e sazonalidade; requerem estacionariedade.
Baseados em Regressão	Ridge, Lasso, Regressão com Fourier	Modelam relação linear entre features e alvo; robustos a overfitting.
Machine Learning	Gradient Boosting (LightGBM, XGBoost)	Capturam não-linearidades; exigem feature engineering cuidadoso.

A combinação de modelos (ensemble) é amplamente utilizada em competições de previsão (M-Competition, Makridakis et al., 2020) por reduzir a variância e o viés individuais de cada estimador. Neste projeto, os pesos foram otimizados empiricamente por busca em grade (grid search) sobre o conjunto de validação, seguindo a metodologia de feature engineering para séries temporais descrita em Hyndman e Athanasopoulos (2021).

2.5 Métricas de Avaliação

O MAPE (Mean Absolute Percentage Error — Erro Percentual Absoluto Médio) é a métrica principal adotada neste projeto. Ele expressa o erro médio em termos percentuais em relação aos valores reais, tornando-se interpretável independentemente da escala do faturamento. Um MAPE de 5% significa que, em média, o modelo erra 5% do valor real a cada previsão. Valores abaixo de 10% são considerados bons para séries de varejo (LEWIS, 1982).

2.6 Documentação do Projeto

O pipeline completo deste projeto foi construído, documentado e disponibilizado publicamente pelo grupo no repositório GitHub: https://github.com/felipencruz/data-mining-ufrj-moda-fitness.

O repositório contém os 17 scripts Python numerados sequencialmente (pasta scripts/), os arquivos de entrada brutos (pasta inputs/) e todos os artefatos intermediários e finais gerados pelo pipeline (pasta outputs/). A estrutura numerada garante que qualquer analista possa reproduzir integralmente os resultados executando os scripts em ordem, partindo exclusivamente dos arquivos na pasta inputs/ — princípio de reprodutibilidade que é um dos pilares da fase de Implantação do CRISP-DM.

3. Dados de Entrada (inputs/)

O projeto utiliza quatro arquivos CSV delimitados por ponto-e-vírgula (;), correspondentes a um modelo dimensional simplificado (esquema estrela) com duas tabelas fato (vendas e estoque) e duas dimensões (clientes e produtos). Todos os arquivos foram fornecidos sem pré-processamento e contêm valores ausentes que foram tratados no pipeline.

Arquivo	Tipo	Registros	Colunas	Colunas Principais
fVendas.csv	Fato	251.000	10	venda_id, data_venda, cliente_id, sku, quantidade, canal_venda, forma_pagamento, preco_base, preco_unitario, valor_total
dClientes.csv	Dimensão	~10.000*	5	cliente_id, idade, genero, uf, data_cadastro
dProdutos.csv	Dimensão	30	4	sku, produto, categoria, preco_base
fEstoque.csv	Fato	30	2	sku, qtd_estoque

(*) Número de clientes únicos estimado a partir da base de vendas.

3.1 Estrutura dos Dados Brutos

A tabela fVendas registra transações individuais de venda realizadas entre abril de 2021 e março de 2026, abrangendo três canais: Loja Física, E-commerce e Instagram. As

formas de pagamento incluem Pix e Cartão de Crédito. O catálogo de produtos contém 30 SKUs distribuídos em 6 categorias de moda fitness.

Categoria	Qtd. de SKUs	Preço Base Unitário
Legging	5	R$ 89,90
Top	5	R$ 45,00
Shorts	5	R$ 59,90
Camiseta Dry-Fit	5	R$ 69,90
Agasalho	5	R$ 189,00
Acessórios	5	R$ 25,00

4. Pipeline de Processamento de Dados

O pipeline foi implementado em 17 scripts Python numerados sequencialmente, garantindo rastreabilidade e reprodutibilidade. Cada script lê os outputs do anterior e gera novos artefatos na pasta outputs/. A seguir, cada etapa é descrita com seus resultados concretos.

4.1 Carregamento, Tratamento de Nulos e Validação de Integridade (Script 01)

O primeiro script carregou as quatro tabelas brutas e realizou o tratamento de valores ausentes com estratégias distintas por coluna, adotando o princípio de imputação por contexto (imputação local) em vez de remoção de registros, preservando a integridade do volume de dados

Campo com Nulo	Estratégia de Imputação	Justificativa
clientes.genero	Moda da UF do cliente	Evita viés nacional; preserva padrão regional

Campo com Nulo	Estratégia de Imputação	Justificativa
vendas.canal_venda	Moda global da coluna	Valor mais frequente no negócio
vendas.forma_pagamento	Moda global da coluna	Valor mais frequente no negócio
vendas.preco_unitario	Substituído pelo preco_base	Preço base como referência de catálogo
vendas.valor_total	Calculado: quantidade × preco_unit.	Regra de negócio determinística

Após a imputação, foi executada a validação de integridade referencial cruzando os identificadores de clientes e SKUs das vendas com as respectivas tabelas dimensionais. Os resultados do relatório de qualidade são:

Métrica de Qualidade	Resultado
Total Linhas Vendas	251.000
Clientes Órfãos	0
Produtos Órfãos	0
Valores Negativos	0
Nulos Restantes	0

4.2 Remoção de Duplicatas (Script 02)

O segundo script analisou a existência de registros duplicados utilizando a combinação de quatro campos como chave natural da transação: [venda_id, data_venda, cliente_id, sku]. Após a deduplicação, foi gerado um identificador sequencial único (transacao_id) para cada linha, substituindo o venda_id original que poderia conter ambiguidades. O resultado encontrado foi de zero duplicatas, confirmando a integridade da fonte.

4.3 Feature Engineering — Clientes (Script 03)

Três variáveis derivadas foram criadas a partir da tabela de clientes para enriquecer o perfil analítico de cada comprador:

Variável Criada	Descrição	Técnica
faixa_etaria	Agrupamento etário em 5 faixas (18-25, 26-35, 36-45, 46-55, 55+)	pd.cut() com bins e labels
dias_desde_cadastro	Dias entre a data de cadastro e 30/03/2026 (data de referência)	Subtração de datas
regiao	Mapeamento de UF para região geográfica (Sudeste / Sul)	Dicionário de correspondência

4.4 Feature Engineering — Vendas (Script 04)

O quarto script enriqueceu a tabela de vendas com sete novas variáveis que transformam dados transacionais em inteligência analítica:

Variável	Descrição
ano, mes, dia_semana	Decomposição temporal da data de venda
nome_dia	Nome do dia da semana (Monday, Tuesday, ...)
eh_fim_semana	Flag binária: 1 se sábado ou domingo
cliente_novo	Flag 1 se a compra ocorreu até 30 dias após cadastro
sazonalidade	Categoria sazonal: Festas, Black Friday, Férias, Pós-Carnaval, Regular
desconto_pct	Percentual de desconto: (preco_base - preco_unit) / preco_base × 100
tem_desconto	Flag 1 se desconto_pct > 0,1%
preco_item	Ticket médio por unidade: valor_total / quantidade

4.5 Consolidação da Base Analítica (Script 05)

Nesta etapa, as quatro tabelas tratadas foram unidas em uma única base analítica por meio de três operações de JOIN (LEFT JOIN via pandas merge()), resultando em uma tabela enriquecida com todas as dimensões disponíveis por linha de venda. O arquivo gerado, df_vendas_final.csv, é a base de partida para todas as análises subsequentes.

Relações de junção realizadas:

Junção	Chave	Variáveis Incorporadas
vendas + clientes	cliente_id	Incorpora gênero, faixa etária, UF, região, tempo de cadastro
+ produtos	sku	Incorpora nome do produto e categoria
+ estoque	sku	Incorpora quantidade disponível em estoque no momento do corte

4.6 Agregação Diária e Mensal (Scripts 06 e 07)

Para a modelagem de séries temporais, a base transacional foi agregada por data de venda, gerando três métricas diárias: total de vendas (transações), faturamento total e unidades vendidas. O mesmo processo foi aplicado em granularidade mensal, acrescentando o percentual de crescimento mês a mês.

Faturamento, Vendas e Clientes por Ano:

Ano	Faturamento Total	Total de Vendas	Clientes Únicos (máx.)
2021 (parcial Abr–Dez)	R$ 7.545.679,80	37.919	3.735
2022	R$ 10.000.944,60	50.019	3.764

Ano	Faturamento Total	Total de Vendas	Clientes Únicos (máx.)
2023	R$ 9.971.479,60	50.166	3.815
2024	R$ 10.096.201,20	50.614	3.759
2025	R$ 9.950.453,60	49.990	3.727
2026 (Jan–Mar real)	R$ 2.435.410,40	12.292	3.721

4.7 Engenharia de Features Temporais e Sazonalidade (Scripts 08 e 09)

Para que os modelos de machine learning pudessem capturar padrões temporais, foram criadas features de memória (lags), suavização (médias móveis) e sazonalidade (transformadas de Fourier e variáveis dummy de eventos). Esta etapa segue a metodologia de feature engineering para séries temporais descrita em Hyndman e Athanasopoulos (2021).

Feature Criada	Descrição e Propósito
faturamento_lag_1	Faturamento do dia anterior (memória de curtíssimo prazo)
faturamento_lag_7	Faturamento de 7 dias atrás (efeito dia da semana)
faturamento_lag_14	Faturamento de 14 dias atrás (ciclo quinzenal)
faturamento_lag_30	Faturamento de 30 dias atrás (ciclo mensal)
faturamento_lag_365	Faturamento do mesmo dia do ano anterior (sazonalidade anual)
media_movel_7d	Média dos últimos 7 dias (suavização de curto prazo)
media_movel_30d	Média dos últimos 30 dias (tendência de médio prazo)
variacao_7d	Desvio padrão dos últimos 7 dias (volatilidade)
onda_sen_1, onda_cos_1	Transformada de Fourier – componente fundamental (ciclo anual)

Feature Criada	Descrição e Propósito
onda_sen_2, onda_cos_2	Transformada de Fourier – segunda harmônica (ciclo semestral)
is_black_friday	Flag 1 para meses de outubro e novembro
is_verao	Flag 1 para meses de dezembro, janeiro, fevereiro e março
is_ferias	Flag 1 para meses de julho e agosto
dia_0 ... dia_6	Dummies para cada dia da semana (segunda a domingo)

Após a criação dos lags, as primeiras 365 linhas (primeiro ano) foram removidas pois não possuíam o valor do lag_365 disponível, resultando em uma base limpa para modelagem iniciada em abril de 2022.

4.8 Divisão Temporal dos Dados (Script 10)

A divisão dos dados para treinamento e avaliação dos modelos seguiu o princípio de validação temporal (walk-forward), no qual o conjunto de treino precede temporalmente os de validação e teste. Este método evita o vazamento de dados futuros (data leakage), garantindo que a avaliação reflita o desempenho real em produção.

Partição	Período	Duração	Finalidade
Treino	Abr/2022 → Dez/2024	~1.006 dias	Aprendizado dos padrões históricos
Validação	Jan/2025 → Dez/2025	365 dias	Otimização de hiperparâmetros e pesos do ensemble
Teste	Jan/2026 → Mar/2026	90 dias	Avaliação final do desempenho real (dados nunca vistos)

4.9 Preparação Estatística para SARIMA (Script 11)

Antes de treinar o modelo SARIMA, foi realizado o Teste de Dickey-Fuller Aumentado (ADF) para verificar a estacionariedade da série. Uma série estacionária possui média e variância constantes ao longo do tempo, condição exigida pelos modelos ARIMA. A transformação logarítmica (log1p) foi aplicada ao faturamento diário para estabilizar a variância, técnica padrão em séries de dados financeiros e de vendas.

5. Modelagem Preditiva

Foram treinados três modelos com abordagens complementares: um modelo puramente estatístico (SARIMA), um modelo de regressão com features de sazonalidade (Prophet-Style com Ridge Regression) e um modelo de machine learning por gradient boosting (LightGBM). Os três foram combinados por um otimizador de pesos em um ensemble final.

5.1 SARIMA — Modelo Autorregressivo Sazonal (Script 12)

O SARIMA (Seasonal AutoRegressive Integrated Moving Average) é uma extensão do modelo ARIMA que incorpora componentes sazonais. Sua notação é SARIMA(p,d,q)(P,D,Q)[s], onde p e q são as ordens AR e MA, d é o grau de diferenciação, e os termos maiúsculos (P,D,Q) com período s representam os componentes sazonais. Neste projeto, foi fixada a estrutura sazonal (1,1,1)[7] (ciclo semanal) e realizou-se busca em grade sobre os parâmetros (p, d=0, q) com p, q ∈ {0, 1, 2}, avaliando o MAPE na validação.

MAPE do SARIMA na validação (2025): 9,08%

5.2 Prophet-Style — Ridge Regression com Features de Fourier (Script 13)

Inspirado na metodologia do Facebook Prophet (Taylor & Letham, 2018), este modelo representa a sazonalidade por meio de pares de senos e cossenos (transformadas de Fourier) como features de uma regressão linear regularizada (Ridge). A regularização L2 (Ridge) penaliza coeficientes muito grandes, controlando o overfitting. O hiperparâmetro alpha foi selecionado por grid search em {0.1, 1, 10, 100, 500}, avaliado pelo MAPE na

validação. Uma variável de tendência linear (número de dias desde o início) também foi incluída para capturar o crescimento de longo prazo.

MAPE do Prophet-Style na validação (2025): 8,28%

5.3 LightGBM — Gradient Boosting em Árvores de Decisão (Script 14)

O LightGBM (Light Gradient Boosting Machine) é um algoritmo de ensemble baseado em gradient boosting que constrói árvores de decisão sequencialmente, cada uma corrigindo os erros da anterior. Distingue-se do XGBoost pelo crescimento de árvores leaf-wise (em vez de level-wise), tornando-o mais eficiente em datasets de alta dimensionalidade. O modelo foi treinado com 200 estimadores, taxa de aprendizado de 0,05 e profundidade máxima de 6, utilizando todas as features numéricas disponíveis (lags, médias móveis, Fourier, dummies de eventos e dias da semana).

MAPE do LightGBM na validação (2025): 5,00%

Importância das variáveis (top 10 por score de ganho):

Feature	Score de Importância
variacao_7d	430
media_movel_7d	372
unidades_dia	363
faturamento_lag_14	253
faturamento_lag_365	249
faturamento_lag_1	247
media_movel_30d	244
faturamento_lag_30	214
faturamento_lag_7	197
onda_sen_1	180

As features de maior importância são indicadores de memória de curtíssimo prazo (variacao_7d, media_movel_7d) e de unidades vendidas no dia, confirmando que o comportamento recente de vendas é o principal preditor do faturamento futuro no contexto de varejo fitness.

5.4 Ensemble — Combinação Ótima de Modelos (Script 15)

O ensemble combina as previsões dos três modelos por média ponderada, com pesos otimizados por busca em grade. Foram testadas todas as combinações (w_sarima, w_prophet, w_lgbm) em passos de 5%, restrita à condição w_sarima + w_prophet + w_lgbm = 1. O critério de seleção foi o menor MAPE no conjunto de validação (2025).

Modelo	Peso no Ensemble	MAPE (Validação 2025)
SARIMA	0%	9,08%
Prophet-Style	10%	8,28%
LightGBM	90%	5,00%
Ensemble Final	—	4,9% (teste 2026)

O otimizador atribuiu peso zero ao SARIMA e concentrou 90% do ensemble no LightGBM. Isso indica que as features de memória temporal (lags e médias móveis) exploradas pelo LightGBM superam a autocorrelação puramente estatística do SARIMA para esta série específica. O MAPE final no conjunto de teste (Jan–Mar 2026, dados nunca vistos) foi de 4,9%, dentro do limiar de aceitação para previsões de varejo (≤ 10%, Lewis, 1982).

6. Previsão de Faturamento 2026 (Scripts 16 e 17)

Com os pesos do ensemble otimizados, ambos os modelos (LightGBM e Prophet-Style) foram retreinados com toda a base histórica disponível (Abr/2021 a Mar/2026) para maximizar a informação disponível antes de projetar o futuro. O LightGBM utilizou previsão recursiva (one-step-ahead), onde a previsão do dia anterior alimenta os lags do dia seguinte, simulando condições reais de produção. O horizonte de previsão cobre os

meses de abril a dezembro de 2026.

6.1 Faturamento Previsto por Mês (Abr–Dez 2026)

Mês de Referência	Faturamento Previsto (R$)
2026-04	R$ 827.219,73
2026-05	R$ 848.725,74
2026-06	R$ 823.621,00
2026-07	R$ 840.937,64
2026-08	R$ 824.370,58
2026-09	R$ 827.005,78
2026-10	R$ 846.903,89
2026-11	R$ 820.681,88
2026-12	R$ 852.656,99

6.2 Consolidação Financeira 2025 vs 2026

Métrica	Valor (R$)	Observação
Faturamento Real 2025	R$ 9.950.453,60	—
Faturamento Real Jan–Mar/2026	R$ 2.435.410,40	Dados reais observados
Faturamento Previsto Abr–Dez/2026	R$ 7.512.123,23	Gerado pelo modelo ensemble
Faturamento Total Projetado 2026	R$ 9.947.533,63	Real + Previsto
Crescimento Anual Projetado (%)	-0,03%	Variação 2026 vs 2025

A projeção indica que o faturamento de 2026 deverá ser praticamente idêntico ao de 2025 (-0,03%), sem crescimento ou queda expressivos. Esse comportamento é coerente com a série histórica observada, que apresentou oscilações mensais em torno de uma média estável ao longo de todo o período analisado, sem tendência de crescimento acelerado.

7. Arquitetura do Pipeline e Artefatos Gerados

O projeto adota uma arquitetura de pipeline baseada em scripts numerados e arquivos intermediários em formato CSV, garantindo rastreabilidade completa de cada etapa. A tabela abaixo mapeia todos os 17 scripts executados com seus respectivos inputs e outputs.

Script	Etapa	Inputs Principais	Outputs Gerados
01	Carregamento e Limpeza	4 arquivos de inputs/	df_*_limpo.csv, relatorio_qualidade.csv
02	Deduplicação	df_vendas_limpo.csv	df_vendas_limpo.csv (atualizado)
03	Features Clientes	df_clientes_limpo.csv	df_clientes_limpo.csv (atualizado)
04	Features Vendas	df_vendas_limpo.csv	df_vendas_limpo.csv (atualizado)
05	Consolidação Final	df_vendas/clientes/produtos/estoque	df_vendas_final.csv
06	Agregação Diária	df_vendas_final.csv	df_vendas_diario.csv
07	Agregação Mensal	df_vendas_final.csv	df_vendas_mensal.csv
08	Features de Tempo (Lags)	df_vendas_diario.csv	df_vendas_diario_lags.csv
09	Features Sazonalidade	df_vendas_diario_lags.csv	df_dataset_previsao.csv

Script	Etapa	Inputs Principais	Outputs Gerados
10	Divisão Temporal	df_dataset_previsao.csv	treino.csv, validacao.csv, teste.csv
11	Preparação SARIMA	df_vendas_diario.csv	base_para_sarima.csv
12	Treino SARIMA	base_para_sarima.csv	pred_sarima_val.csv, pred_sarima_test.csv
13	Treino Prophet-Style	treino/validacao/teste.csv	pred_prophet_val.csv, pred_prophet_test.csv
14	Treino LightGBM	treino/validacao/teste.csv	pred_lgbm_val/test.csv, lgbm_importancia.csv
15	Ensemble	pred_*/val/test.csv	predicao_final_ensemble.csv, pesos_ensemble.csv
16	Previsão Futuro 2026	df_completo + pesos_ensemble.csv	previsao_financeira_2026.csv
17	Relatório Executivo	df_vendas_diario + previsao_2026	relatorio_executivo_final.csv

8. Conclusões

Este projeto demonstrou a aplicação end-to-end do processo de Data Mining em um contexto real de varejo de moda fitness. Partindo de dados brutos com valores ausentes e sem estrutura analítica, o pipeline produziu um modelo preditivo com erro médio de apenas 4,9% no conjunto de teste, viabilizando projeções financeiras confiáveis para o planejamento estratégico de 2026.

Os principais achados do projeto são:

Qualidade de dados robusta: O processo de ETL garantiu 251.000 transações sem nulos residuais, sem valores negativos e sem registros órfãos, base fundamental para qualquer análise confiável.

Domínio do LightGBM: O LightGBM recebeu 90% do peso no ensemble, confirmando que features de memória temporal (lags e médias móveis) são mais preditivas que a autocorrelação estatística pura do SARIMA para esta série.

Sazonalidade estável: A série histórica de 5 anos não apresenta tendência de crescimento acelerado. O padrão sazonal é regular, com quedas em fevereiro e picos em meses de começo de estação, comportamento típico do varejo fitness.

Projeção financeira 2026: O faturamento total projetado para 2026 é de R$ 9.947.533,63, praticamente estável em relação a 2025 (variação de -0,03%), sustentado por R$ 2.435.410,40 de receita já realizada (Jan–Mar) e R$ 7.512.123,23 de receita prevista pelo modelo (Abr–Dez).

Reprodutibilidade: O pipeline numerado garante que qualquer analista pode reproduzir os resultados executando os scripts na ordem sequencial, partindo exclusivamente dos arquivos na pasta inputs/. A documentação completa do projeto está disponível no repositório GitHub público: https://github.com/felipencruz/data-mining-ufrj-moda-fitness.

8.1 Referências

data-mining-ufrj-moda-fitness. Repositório GitHub, 2026. Disponível em: https://github.com/felipencruz/data-mining-ufrj-moda-fitness. Acesso em: abr. 2026.

LATTA, Cláudio. Data Mining. Material de aula. MBA em Engenharia de Dados, UFRJ, 2026.

FAYYAD, Usama; PIATETSKY-SHAPIRO, Gregory; SMYTH, Padhraic. From Data Mining to Knowledge Discovery in Databases. AI Magazine, v. 17, n. 3, p. 37–54, 1996. Disponível em: https://ojs.aaai.org/aimagazine/index.php/aimagazine/article/view/1230.

HAN, Jiawei; KAMBER, Micheline; PEI, Jian. Data Mining: Concepts and Techniques. 3. ed. Burlington: Morgan Kaufmann, 2011.

HAND, David J.; MANNILA, Heikki; SMYTH, Padhraic. Principles of Data Mining. Cambridge: MIT Press, 2001. Disponível em: https://www.semanticscholar.org/paper/Principles-of-Data-Mining.

HYNDMAN, Rob J.; ATHANASOPOULOS, George. Forecasting: Principles and Practice. 3. ed. Melbourne: OTexts, 2021. Disponível em: https://otexts.com/fpp3.

IBM. IBM SPSS Modeler CRISP-DM Guide. Versão reformulada do guia original de 2001. Armonk: IBM, 2011. Disponível em: https://www.ibm.com/docs/en/spss-modeler.
LEWIS, Colin D. Industrial and Business Forecasting Methods. Londres: Butterworths, 1982.

MAKRIDAKIS, Spyros; SPILIOTIS, Evangelos; ASSIMAKOPOULOS, Vassilios. The M4 Competition: 100,000 time series and 61 forecasting methods. International Journal of Forecasting, v. 36, n. 1, p. 54–74, 2020.

TAYLOR, Sean J.; LETHAM, Benjamin. Forecasting at scale. The American Statistician, v. 72, n. 1, p. 37–45, 2018.